



Prediksi Kelayakan Kredit Nasabah Menggunakan Decision Tree (CART) dan Random Forest

Khairunnisa Maharani¹, Azzahra Putri Kamilah², Cindy Laura Manik³, Adit Taufiqurrohman⁴, Muhammad Dzikra⁵

^{1, 2, 3, 4}Sains Data, Fakultas Sains, Institut Teknologi Sumatera

¹khairunnisa.123450071@student.its.ac.id

²azzahra.123450013@student.its.ac.id

³cindy.123450112@student.its.ac.id

⁴aditya.123450032@student.its.ac.id

⁵muhammad.123450124@student.its.ac.id

Corresponding author email: khairunnisa.123450071@student.its.ac.id

Abstract: This study compares Classification and Regression Trees (CART) and Random Forest (RF) models for creditworthiness assessment, addressing class imbalance challenges through the ROSE technique. Utilizing the German Credit Dataset, we evaluated both algorithms on balanced and unbalanced data, with additional analysis of CART pruning effects. As a baseline approach, feature engineering and explicit feature selection were not performed. Research findings indicate that balanced RF demonstrated superior performance (67.06% Balanced Accuracy, 68.57% Recall for "Bad" class) with the highest F1-score and Kappa values. CART models offered better interpretability but lower accuracy. Data balancing significantly improved minority class detection, while pruning reduced model complexity at the cost of sensitivity. Five consistent predictive variables emerged: Account Status, Savings/Bonds, Credit Purpose, Credit History, and Employment—with Account Status being the most influential determinant. This research contributes to developing more objective and efficient technology-based credit assessment systems for financial institutions in Indonesia, offering valuable input for credit risk management regulators.

Keywords: credit assessment, machine learning, CART, Random Forest, class imbalance

Abstrak: Penelitian ini membandingkan model Classification and Regression Trees (CART) dan Random Forest (RF) untuk penilaian kelayakan kredit, mengatasi tantangan ketidakseimbangan kelas melalui teknik ROSE. Menggunakan German Credit Dataset, kami mengevaluasi kedua algoritma pada data seimbang dan tidak seimbang, dengan analisis tambahan efek pemangkasan CART. Sebagai pendekatan baseline, *feature engineering* dan seleksi fitur eksplisit tidak dilakukan. Hasil penelitian menunjukkan bahwa RF dengan *balancing* mendemonstrasikan performa terbaik (Balanced Accuracy 67,67%, Recall kelas "Buruk" 68,57%) dengan nilai F1-score dan Kappa tertinggi. Model CART menawarkan interpretabilitas lebih baik namun akurasi lebih rendah. Penyeimbangan data secara signifikan meningkatkan deteksi kelas minoritas, sementara *pruning* mereduksi kompleksitas model dengan mengorbankan sensitivitas. Lima variabel prediktif konsisten ditemukan: Status Rekening, Tabungan/Bonds, Tujuan Kredit, Riwayat Kredit, dan Pekerjaan—dengan Status Rekening sebagai determinan paling berpengaruh. Penelitian ini berkontribusi pada pengembangan sistem penilaian kredit berbasis teknologi yang lebih objektif dan efisien bagi lembaga keuangan di Indonesia, memberikan masukan berharga bagi regulator pengelolaan risiko kredit.

Kata kunci: penilaian kredit, machine learning, CART, Random Forest, ketidakseimbangan kelas

1. PENDAHULUAN

Penilaian kelayakan kredit merupakan aspek krusial dalam manajemen risiko lembaga keuangan, terlebih di Indonesia yang mencatat inklusi keuangan sebesar 76,19% pada 2022 [1]. Proses penilaian secara tradisional cenderung subjektif dan memakan waktu, sehingga mendorong adopsi metode machine learning yang lebih efisien [2]. Penelitian ini mengimplementasikan dan membandingkan Classification and Regression Trees (CART) dan Random Forest dalam prediksi kelayakan kredit. CART dipilih karena keunggulannya dalam interpretabilitas bagi pemangku kepentingan non-teknis [3], sedangkan Random Forest diutamakan karena akurasinya yang lebih tinggi meskipun kurang



SENADA
Seminar Nasional Sains Data

Seminar Nasional Sains Data 2024 (SENADA 2024)

UPN “Veteran” Jawa Timur

E-ISSN 2808-5841

P-ISSN 2808-7283

transparan [4]. Menurut Lessmann dkk. [5], kombinasi kedua pendekatan tersebut memberikan keseimbangan antara akurasi dan interpretasi, dua aspek yang sering menjadi *trade-off* dalam pemodelan keuangan.

Tantangan utama dalam pemodelan kelayakan kredit adalah ketidakseimbangan kelas, di mana kredit bermasalah jauh lebih sedikit dibanding kredit lancar [6]. Oleh karena itu, penelitian ini juga membandingkan performa model pada data *balanced* dan *unbalanced*, serta mengevaluasi efek pemangkasan (*pruning*) pada CART untuk mengurangi kompleksitas model [7]. Meski menggunakan *German Credit Dataset* [8], studi ini tetap relevan dalam konteks Indonesia karena prinsip dasar penilaian kredit bersifat universal, dataset tersebut telah menjadi benchmark global [9], dan variabel yang digunakan selaras dengan praktik lokal [10]. Hasil penelitian ini diharapkan dapat mendukung pengembangan sistem penilaian kredit berbasis teknologi yang lebih objektif dan efisien bagi lembaga keuangan di Indonesia, serta memberikan masukan bagi regulator dalam pengelolaan risiko kredit.

2. METODE PENELITIAN

2.1. Data dan Sumber Data

Penelitian ini menggunakan *German Credit Dataset* yang diperoleh dari *UCI Machine Learning Repository*, berisi 1000 data pemohon kredit dengan 20 variabel prediktor dan satu variabel target berupa klasifikasi kelayakan kredit (“baik” atau “buruk”) berdasarkan riwayat pembayaran. Dataset ini dipilih karena tersedia secara publik, memiliki kualitas data yang baik, serta telah menjadi *benchmark* dalam berbagai penelitian terkait pemodelan kelayakan kredit berbasis *machine learning*. [8]. Dataset ini mencakup atribut-atribut penting seperti status rekening, durasi pinjaman, jumlah tabungan, pekerjaan, dan tujuan kredit, yang juga relevan untuk konteks sistem kredit di Indonesia [10].

2.2. Variabel Penelitian

German Credit Dataset terdiri dari 20 variabel prediktor dan 1 variabel target. Variabel-variabel prediktor merepresentasikan aspek-aspek penting dari pemohon kredit, seperti status rekening, riwayat kredit, jumlah pinjaman, status pekerjaan, serta karakteristik demografis lainnya. Sementara itu, variabel target berupa klasifikasi kelayakan kredit yang terbagi menjadi dua kategori: “Baik” dan “Buruk” [1].

Deskripsi lengkap masing-masing variabel yang digunakan dalam penelitian ini disajikan pada tabel berikut:

Tabel 1. Deskripsi Variabel dalam *Dataset German Credit*

Nama Variabel	Deskripsi	Deskripsi Kategori
Status Rekening	Status rekening nasabah di bank	Kurang dari 0 DM, 0–199 DM, 200 DM ke atas / gaji tetap, Tidak ada rekening
Durasi dalam bulan	Durasi kredit dalam bulan	Nilai numerik (misalnya: 12, 24, dst.)
Riwayat Kredit	Riwayat pembayaran kredit sebelumnya	Tidak pernah kredit / semua kredit lancar, Kredit di bank ini lancar, Kredit berjalan lancar, Pernah telat bayar, Ada masalah / kredit di luar bank
Tujuan Kredit	Tujuan pengajuan kredit	Mobil baru, Mobil bekas, Furniture, TV / Radio, Peralatan rumah, Renovasi,



SENADA
Seminar Nasional Sains Data

Seminar Nasional Sains Data 2024 (SENADA 2024)
UPN “Veteran” Jawa Timur

E-ISSN 2808-5841

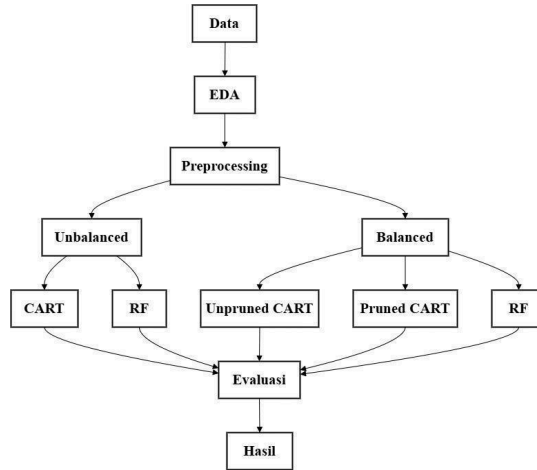
P-ISSN 2808-7283

		Pendidikan, Liburan, Pelatihan ulang, Bisnis, Lainnya
Jumlah Kredit (DM)	Jumlah kredit dalam Deutsche Mark	Nilai numerik
Tabungan/Bonds	Tabungan atau obligasi yang dimiliki nasabah	Kurang dari 100 DM, 100–499 DM, 500–999 DM, 1000 DM ke atas, Tidak punya / tidak tahu
Pekerjaan Saat Ini	Lama bekerja pada pekerjaan saat ini	Menganggur, Kurang dari 1 tahun, 1–4 tahun, 4–7 tahun, 7 tahun atau lebih
Tingkat Angsuran (%)	Persentase pendapatan yang digunakan untuk angsuran	Nilai numerik (persen dari penghasilan)
Status Pribadi dan Jenis Kelamin	Status pernikahan dan jenis kelamin	Pria cerai/pisah, Wanita menikah/cerai, Pria lajang, Pria menikah/duda, Wanita lajang
Debitur/Penjamin	Keberadaan debitur atau penjamin lain	Tidak ada, Ko-pemohon, Penjamin
Tinggal di Tempat Saat Ini	Lama tinggal di alamat saat ini	Nilai numerik (jumlah tahun)
Properti	Kepemilikan properti	Properti, Tabungan/Asuransi, Mobil / lainnya, Tidak ada / tidak tahu
Usia (tahun)	Usia nasabah dalam tahun	Nilai numerik
Rencana Angsuran Lain	Keberadaan rencana angsuran lain	Bank, Toko, Tidak ada
Tempat Tinggal	Status kepemilikan tempat tinggal	Sewa, Milik sendiri, Gratis
Jumlah Kredit di Bank Ini	Jumlah kredit yang dimiliki di bank yang sama	Nilai numerik
Pekerjaan	Jenis pekerjaan nasabah	Pengangguran / tidak terampil (non-residen), Tidak terampil (residen), Terampil / pegawai, Manajer / profesional
Jumlah Tanggungan	Jumlah tanggungan nasabah	Nilai numerik
Nomor Telepon	Kepemilikan nomor telepon	Tidak ada, Ada
Pekerja Migran	Status sebagai pekerja migran	Ya, Bukan
Kelayakan Kredit (Target)	Kategori "Baik" atau "Buruk" berdasarkan riwayat pembayaran	Nilai kategorikal (Baik/Buruk)

2.3. Tahapan Penelitian

Penelitian ini dilakukan secara sistematis, dimulai dari eksplorasi dan pra-pemrosesan data, mencakup analisis distribusi, penanganan missing value, dan transformasi variabel kategorikal. Ketidakseimbangan kelas ditangani menggunakan teknik ROSE untuk menghasilkan sampel sintesis dengan distribusi serupa data asli. Pemodelan menggunakan algoritma CART dan *Random Forest*, masing-masing diuji pada data asli dan data yang telah diseimbangkan. CART dibangun dengan dan tanpa *pruning*, menggunakan parameter $cp = 0.01$, $minbucket = 5$, dan $minsplit = 10$. *Random Forest* menggunakan $ntree = 500$ dan $mtry = \sqrt{\text{jumlah variabel prediktor}}$. Evaluasi dilakukan dengan confusion matrix dan metrik seperti akurasi, recall, spesifisitas, presisi, Kappa, dan *Balanced Accuracy*, untuk membandingkan kinerja model serta pengaruh penyeimbangan data dan *pruning*.

Pada tahap ini, analisis dilakukan tanpa *feature engineering* dan *feature selection* eksplisit untuk mengevaluasi performa baseline model terhadap fitur asli yang tersedia. Langkah ini bertujuan sebagai titik awal sebelum melakukan optimasi lebih lanjut.



Gambar 1. Diagram Alir

2.4. Algoritma CART

Classification and Regression Trees (CART) adalah metode *decision tree* yang dikembangkan oleh Breiman et al. [3]. CART bekerja dengan membagi ruang fitur secara rekursif untuk membentuk subset data yang semakin homogen berdasarkan variabel prediktor. Kriteria pemilihan *split* terbaik menggunakan *Gini Impurity* yang didefinisikan sebagai:

$$Gini(t) = 1 - \sum_{j=1}^J [p(j/t)]^2 \quad (1)$$

di mana $p(j/t)$ merupakan proporsi data kelas ke- j pada node t . Semakin kecil nilai *Gini*, semakin homogen data dalam node tersebut. CART memiliki keunggulan utama pada interpretabilitas, karena hasil model dapat divisualisasikan sebagai pohon keputusan yang mudah dipahami.

Untuk menghindari *overfitting*, CART menggunakan metode *cost-complexity pruning* dengan fungsi penalti sebagai berikut:

$$R_{\alpha}(T) = R(T) + \alpha|T| \quad (2)$$

dengan $R(T)$ adalah galat total pada tree T , $|T|$ adalah jumlah node terminal, dan α adalah parameter kompleksitas. Nilai α ditentukan melalui pendekatan *1-standard error rule* [7].

2.5. Algoritma Random Forest

Random Forest adalah metode *ensemble learning* yang menggabungkan banyak pohon keputusan untuk menghasilkan prediksi yang lebih akurat dan stabil [4]. Setiap pohon dibangun dari sampel *bootstrap* X_b berukuran n , dan pada setiap *split* hanya mempertimbangkan subset acak dari m_{try} variabel prediktor.



Prediksi akhir diperoleh melalui rata-rata hasil prediksi dari seluruh pohon, dirumuskan sebagai:

$$f_{rf}(x) = \frac{1}{B} \sum_{b=1}^B f_b(x) \quad (2)$$

dengan B adalah jumlah pohon dalam model dan $f_b(x)$ adalah prediksi dari pohon ke- b . Dengan pendekatan ini, *Random Forest* umumnya lebih tahan terhadap *overfitting* dan memiliki akurasi tinggi, meskipun interpretabilitasnya lebih rendah dibandingkan CART. Namun, algoritma ini tetap menyediakan fitur penting seperti *variable importance*.

2.6. Teknik Penyeimbangan Kelas dengan ROSE

ROSE (*Random Over-Sampling Examples*) adalah teknik penyeimbangan kelas yang diperkenalkan oleh Menardi dan Torelli [11], bekerja dengan menghasilkan sampel sintesis menggunakan estimasi kepadatan *kernel*. Keunggulan ROSE terletak pada kemampuannya menciptakan dataset yang seimbang tanpa kehilangan informasi penting, menghindari *overfitting*, dan membentuk batas keputusan yang lebih halus. ROSE menghasilkan dataset baru dengan distribusi kelas yang seimbang, sehingga mengurangi bias terhadap kelas mayoritas dalam pembelajaran model.

2.7. Metrik Evaluasi

Evaluasi model dilakukan menggunakan metrik Akurasi, Recall, Spesifisitas, F1-Score, Kappa dan Balanced Accuracy. Metrik ini memberikan gambaran menyeluruh mengenai performa model, dengan Recall mewakili kemampuan mendeteksi kredit “Baik” dan spesifisitas untuk kredit “Buruk”. Dalam konteks penilaian kredit, keseimbangan antara sensitivitas dan spesifisitas sangat krusial karena berkaitan langsung dengan risiko bisnis dan kebijakan lembaga keuangan.

3. HASIL DAN PEMBAHASAN

3.1. Deskripsi Data

Dataset German Credit yang digunakan dalam penelitian ini terdiri dari 1000 data nasabah dengan distribusi awal 700 nasabah (70%) dengan kredit “Baik” dan 300 nasabah (30%) dengan kredit “Buruk”.

Karakteristik statistik dari beberapa variabel numerik penting ditampilkan pada Tabel 2.

Tabel 2. Statistik Deskriptif Variabel Numerik

Nama Variabel	Min	1st Qu	Median	Mean	3rd Qu	Max
Durasi dalam bulan	4	12	18	20.9	24	72
Jumlah Kredit (DM)	250	1366	2320	3271	3972	18424
Tingkat Angsuran	1	2	3	2.973	4	4



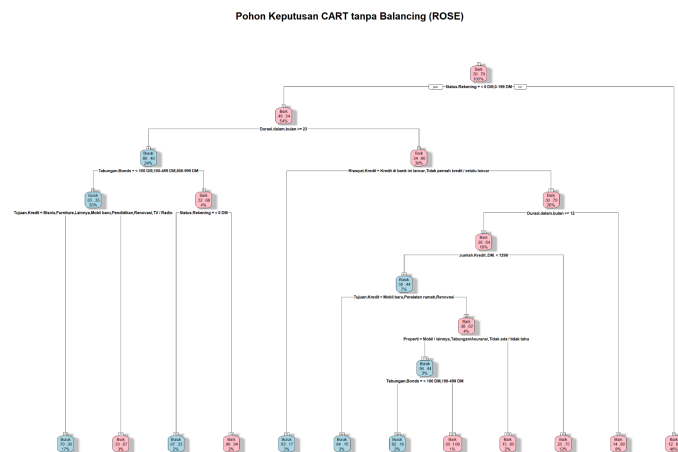
E-ISSN 2808-5841
P-ISSN 2808-7283

Tinggal di Tempat Saat Ini	1	2	3	2.845	4	4
Usia (Tahun)	19	27	33	35.55	42	75
Jumlah Kredit di Bank Ini	1	1	1	1.407	2	4
Jumlah Tanggungan	1	1	1	1.155	1	2

Hasil eksplorasi data tidak menunjukkan adanya *missing value* pada dataset, sehingga tidak diperlukan teknik khusus untuk penanganan data yang hilang.

3.2.1. Model CART tanpa Penyeimbangan Kelas

Model CART pertama dibangun menggunakan dataset original tanpa penyeimbangan kelas. Struktur pohon keputusan yang dihasilkan menunjukkan variabel-variabel yang paling berpengaruh dalam penentuan kelayakan kredit nasabah.



Gambar 2. Visualisasi Pohon Keputusan CART tanpa Penyeimbangan Kelas.

Model pohon keputusan tanpa penerapan teknik penyeimbangan kelas (ROSE) menunjukkan struktur yang cukup dalam, dengan pemisahan utama berdasarkan variabel Status.Rekening, khususnya kategori saldo sangat rendah (< 0 DM dan 0–199 DM). Variabel ini menjadi akar pohon, menandakan pentingnya kondisi rekening awal nasabah dalam menentukan kelayakan kredit. Cabang-cabang berikutnya menampilkan kombinasi variabel seperti durasi pinjaman, jumlah simpanan, tujuan kredit, serta riwayat kredit dan jenis properti. Contohnya, nasabah dengan rekening negatif, durasi pinjaman



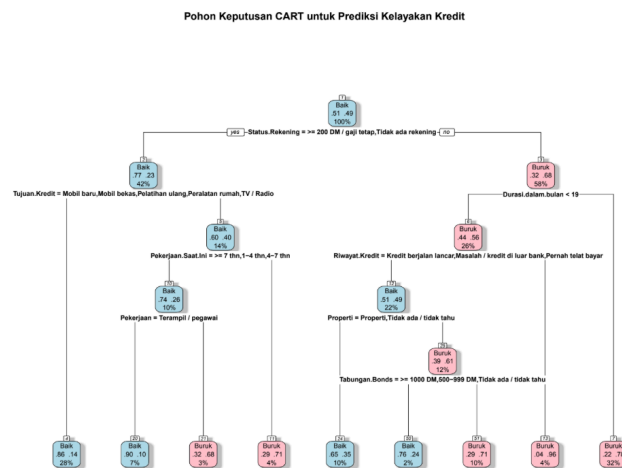
≥ 23 bulan, dan tabungan < 1000 DM, terutama dengan tujuan konsumtif seperti pembelian perabot, lebih cenderung diklasifikasikan sebagai “Buruk”.

Meskipun struktur pohon cukup transparan dan dapat diinterpretasikan, distribusi prediksi di beberapa node menunjukkan bias terhadap kelas mayoritas. Beberapa daun memiliki proporsi kelas “Baik” hingga 86%, sementara sensitivitas terhadap kelas “Buruk” tergolong rendah, menunjukkan bahwa model lebih akurat mengenali nasabah layak kredit dibanding nasabah berisiko. Hal ini mencerminkan konsekuensi dari ketidakseimbangan kelas yang tidak ditangani, menjadikan model ini baseline penting sebelum dibandingkan dengan varian yang menggunakan balancing ROSE atau pemangkasan (pruning) untuk mengevaluasi kinerja dan kompleksitas.

Evaluasi model CART tanpa penyeimbangan kelas pada dataset testing menghasilkan akurasi sebesar 72.33%, dengan sensitivitas 83.81% dan spesifisitas 45.56%. Detail hasil evaluasi dapat dilihat pada Tabel 3.

3.2.2. Model CART dengan Penyeimbangan ROSE

Model CART kedua dibangun menggunakan dataset yang telah diseimbangkan dengan teknik ROSE. Struktur pohon keputusan yang dihasilkan dapat dilihat pada Gambar 3.



Gambar 3. Visualisasi Pohon Keputusan CART dengan Penyeimbangan ROSE.


Setelah diterapkan teknik ROSE untuk menyeimbangkan kelas, struktur pohon keputusan CART berubah signifikan, dengan akar pohon kini ditentukan oleh variabel Status.Rekening pada kategori saldo cukup tinggi atau tanpa rekening. Percabangan utama selanjutnya melibatkan Tujuan.Kredit, jenis Pekerjaan, dan Pekerjaan.Saat.Ini, yang menggambarkan preferensi konsumsi serta stabilitas pekerjaan nasabah. Variabel lain seperti durasi pinjaman, riwayat kredit, properti, dan tabungan juga terlibat, memperkuat pemetaan terhadap kondisi keuangan dan rekam jejak historis nasabah.

Distribusi prediksi pada node terminal menjadi lebih seimbang, dengan peningkatan sensitivitas terhadap kelas “Buruk” yang sebelumnya cenderung terabaikan. Beberapa node menunjukkan proporsi signifikan terhadap kelas minoritas, menandakan keberhasilan ROSE dalam mengurangi bias



terhadap kelas mayoritas. Meskipun sebagian besar daun masih mendominasi prediksi kelas “Baik”, model ini menunjukkan kemampuan lebih baik dalam mengenali pola risiko, menjadikannya alat bantu yang lebih akurat untuk mitigasi risiko kredit, meski tetap perlu diwaspadai potensi overfitting.

Variabel yang digunakan dalam pembentukan pohon keputusan meliputi:



Gambar 4. Visualisasi 10 Variabel Terpenting dalam Model CART *Balanced*.


Evaluasi model CART dengan penyeimbangan kelas menunjukkan akurasi sebesar 63.67%, dengan sensitivitas 63.81% dan spesifisitas 63.33%. Meskipun akurasi keseluruhan menurun dibandingkan model tanpa penyeimbangan, namun terjadi peningkatan signifikan pada spesifisitas, yang menunjukkan kemampuan model yang lebih baik dalam mengidentifikasi nasabah dengan kredit "Buruk".

3.2.3. Model CART dengan *Pruning*

Untuk mengoptimalkan model CART, dilakukan *pruning* menggunakan metode *cost-complexity pruning*. Berdasarkan metode *1-standard error rule*, nilai optimal *Complexity Parameter* (CP) yang dipilih adalah 0.0205.

Model CART yang telah di-*pruning* menghasilkan pohon keputusan yang lebih sederhana namun tetap mempertahankan kemampuan prediktif yang baik.

Pohon Keputusan CART (Pruned) untuk Prediksi Kelayakan Kredit






Gambar 5. Visualisasi Pohon Keputusan CART setelah *Pruning*.

Model CART hasil *balancing* dengan ROSE yang kemudian dipangkas (*pruned*) menunjukkan struktur sangat sederhana, hanya dengan satu percabangan utama. Pemangkasan ini bertujuan mengurangi kompleksitas dan mencegah *overfitting* yang mungkin muncul akibat *balancing*. Node akar tetap berasal dari Status.Rekening, dengan pembagian antara nasabah dengan saldo tinggi atau penghasilan tetap versus saldo rendah. Hasilnya adalah dua daun terminal yang secara langsung mengelompokkan nasabah berdasarkan kelayakan kredit.

Distribusi prediksi menunjukkan bahwa nasabah dengan rekening stabil didominasi kelas “Baik” (77%), sedangkan yang bermasalah cenderung diklasifikasikan “Buruk” (68%). Meskipun sangat sederhana, model ini efektif dalam menangkap pola dominan dan sangat cocok untuk konteks pengambilan keputusan yang membutuhkan transparansi dan interpretabilitas tinggi. Namun, penyederhanaan ini juga berisiko mengabaikan kontribusi fitur lain, sehingga tetap perlu dievaluasi dari sisi performa keseluruhan.

Variabel yang digunakan dalam pembentukan pohon keputusan meliputi:



Gambar 6. Visualisasi 10 Variabel Terpenting dalam Model CART *Balanced (Pruned)*.

Evaluasi model CART dengan *pruning* menunjukkan akurasi sebesar 60.33%, dengan sensitivitas 53.81% dan spesifisitas 75.56%. Menariknya, *pruning* meningkatkan spesifisitas model dengan signifikan, meskipun pada saat yang sama menurunkan sensitivitas.

3.3. Pemodelan dengan *Random Forest*

3.3.1. *Random Forest* tanpa Penyeimbangan Kelas

Model *Random Forest* pertama dibangun menggunakan dataset original tanpa penyeimbangan kelas. Dengan menggunakan 500 pohon keputusan dan $mtry = \sqrt{\text{jumlah variabel}}$, model ini dapat menangkap pola kompleks dalam data.

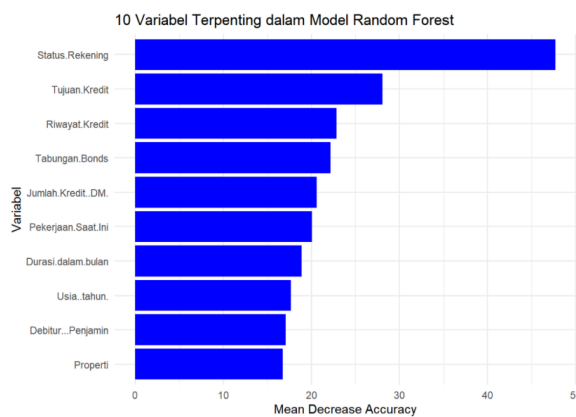
Evaluasi model *Random Forest* tanpa penyeimbangan kelas menghasilkan akurasi sebesar 75.33%, dengan sensitivitas 90% dan spesifisitas 41.11%. Detail hasil evaluasi dapat dilihat pada Tabel 4.



3.3.2. *Random Forest* dengan Penyeimbangan ROSE

Model *Random Forest* kedua dibangun menggunakan dataset yang telah diseimbangkan dengan teknik ROSE. Model ini menghasilkan *Out-of-Bag* (OOB) *error rate* sebesar 15.71%, yang menunjukkan performa yang cukup baik.

Variabel yang digunakan dalam pembentukan pohon keputusan meliputi:



Gambar 7. Visualisasi 10 Variabel Terpenting dalam Model *Random Forest Balanced*.

Evaluasi model *Random Forest* dengan penyeimbangan kelas menunjukkan akurasi sebesar 67.67%, dengan sensitivitas 68.57% dan spesifisitas 65.56%. Sama seperti pada model CART, penyeimbangan kelas pada *Random Forest* juga menurunkan akurasi keseluruhan tetapi meningkatkan keseimbangan antara sensitivitas dan spesifisitas.

3.4. Perbandingan Kinerja Model

Perbandingan kinerja dari berbagai model yang telah dibangun dalam penelitian ini disajikan dalam Tabel 3.

Tabel 3. Perbandingan Kinerja Model dengan Dataset Seimbang dan tak seimbang

Model	Akurasi	Recall(Baik)	Specificity (Buruk)	F1-Score	Kappa	Balanced Accuracy
CART (Balance)	63.67%	63.81%	63.33%	71.09%	0.2388	63.57%
CART (Unbalance)	72.33%	83.81%	45.56%	80.93%	0.3083	64.68%
CART (Pruned)	60.33%	53.81%	75.56%	65.37%	0.2372	64.68%
RF (Balance)	67.67%	68.57%	65.56%	74.76%	0.3071	67.06%
RF (Unbalance)	75.33%	90.00%	41.11%	83.56%	0.3463	65.56%

Dari temuan tersebut, berikut ini *insight* yang di dapatkan:



1. **Efek *Balancing* pada Model CART:** Implementasi teknik ROSE meningkatkan sensitivitas terhadap kelas minoritas "Buruk" dan menghasilkan struktur keputusan yang lebih ekuitable, sementara *pruning* mereduksi kompleksitas pohon secara signifikan—meningkatkan interpretabilitas dengan potensi *trade-off* akurasi.
2. **Evolusi Pohon Model CART:** Model *unbalanced* menampilkan pohon dengan bias ke kelas mayoritas dengan Status.Rekening sebagai akar (fokus pada saldo rendah); model *balanced* menghasilkan struktur lebih kompleks dengan peningkatan sensitivitas kelas "Buruk" dan diversifikasi prediktor; sementara model *pruned* tereduksi menjadi struktur minimalis satu-percabangan yang mempertahankan Status.Rekening sebagai determinan utama kelayakan kredit.
3. **Perbandingan Kinerja:** RF *balanced* unggul dalam Balanced Accuracy (67,67%) dan Recall "Buruk" (68,57%), sementara CART *balanced* menunjukkan deteksi lebih seimbang untuk kedua kelas dengan interpretabilitas superior namun kurang akurat dibanding RF.
4. **Rekomendasi Model:** RF *Balanced* mendemonstrasikan performa optimal (Balanced Accuracy 67,67%, Recall "Buruk" 68,57%) dengan F1-score dan Kappa tertinggi di metode *balanced*, menjadikannya superior untuk asesmen kelayakan kredit.
5. **Determinan Prediktif:** Lima variabel dengan signifikansi konsisten: Status.Rekening, Tabungan/Bonds, Tujuan.Kredit, Riwayat.Kredit, dan Pekerjaan—dengan Status.Rekening sebagai prediktor utama dalam model.

Berdasarkan hasil yang diperoleh, terlihat potensi untuk peningkatan performa model melalui teknik *feature engineering* seperti pembuatan rasio kredit dan seleksi fitur berdasarkan korelasi atau *importance score*.

4. KESIMPULAN

Penelitian ini menunjukkan bahwa *Random Forest* dengan *balancing* merupakan model terbaik dalam memprediksi kelayakan kredit, dengan Balanced Accuracy dan Recall kelas "Buruk" tertinggi. Teknik ROSE terbukti efektif meningkatkan deteksi terhadap kredit "Buruk", sedangkan *pruning* pada CART menyederhanakan struktur pohon namun mengorbankan sensitivitas. CART *balanced* menghasilkan model yang lebih adil secara kelas dengan interpretabilitas tinggi, meskipun kurang akurat dibanding *Random Forest*. Lima variabel prediktif utama yang konsisten ditemukan, yakni Status.Rekening, Tabungan/Bonds, Tujuan.Kredit, Riwayat.Kredit, dan Pekerjaan—dengan Status.Rekening sebagai determinan paling dominan. Implikasinya, pemilihan model harus disesuaikan dengan kebutuhan bisnis antara akurasi dan transparansi. Langkah berikutnya dapat mencakup eksplorasi *feature engineering* dan seleksi fitur untuk memperkuat model dan mendorong interpretasi yang lebih baik, disertai studi lanjutan yang mengeksplorasi algoritma seperti *Gradient Boosting* dan *Deep Learning*, serta mempertimbangkan penggunaan dataset lokal guna meningkatkan relevansi kontekstual dalam pengambilan keputusan kredit.

UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih kepada Program Studi Sains Data, Institut Teknologi Sumatera atas dukungan fasilitas, infrastruktur, dan bimbingan akademik selama proses pengerjaan tugas besar ini. Ucapan khusus ditujukan kepada Ibu Mika Alvionita S, S.Si., M.Si. selaku dosen pengampu mata



kuliah atas arahan, penjelasan materi, dan kesempatan mendalami topik analisis kelayakan kredit dengan pendekatan eksplorasi data dan algoritma pembelajaran mesin. Apresiasi juga disampaikan kepada seluruh anggota kelompok atas kerja sama, diskusi aktif, dan dukungan dalam penyusunan laporan ini, serta kepada *UCI Machine Learning Repository* atas penyediaan *dataset German Credit* sebagai bahan utama analisis. Semoga laporan ini memberikan kontribusi pengetahuan dan menjadi pembelajaran bermakna dalam penerapan data science di bidang keuangan.

Daftar Pustaka

- [1] Otoritas Jasa Keuangan, "Survei Nasional Literasi dan Inklusi Keuangan (SNLIK) 2022," Jakarta, 2022.
- [2] Khandani, A. E., Kim, A. J., & Lo, A. W., "Consumer credit-risk models via machine-learning algorithms," *Journal of Banking & Finance*, 34(11), 2767-2787, 2010.
- [3] Breiman, L., Friedman, J., Stone, C. J., & Olshen, R. A., "Classification and Regression Trees," CRC Press, Boca Raton, 1984.
- [4] Breiman, L., "Random Forests," *Machine Learning*, 45(1), 5-32, 2001.
- [5] Lessmann, S., Baesens, B., Seow, H. V., & Thomas, L. C., "Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research," *European Journal of Operational Research*, 247(1), 124-136, 2015.
- [6] Brown, I., & Mues, C., "An experimental comparison of classification algorithms for imbalanced credit scoring data sets," *Expert Systems with Applications*, 39(3), 3446-3453, 2012.
- [7] Mingers, J., "An empirical comparison of pruning methods for decision tree induction," *Machine Learning*, 4(2), 227-243, 1989.
- [8] H. Hofmann. "Statlog (German Credit Data)," UCI Machine Learning Repository, 1994. [Online]. Available: <https://doi.org/10.24432/C5NC77>.
- [9] Baesens, B., Van Gestel, T., Viaene, S., Stepanova, M., Suykens, J., & Vanthienen, J., "Benchmarking state-of-the-art classification algorithms for credit scoring," *Journal of the Operational Research Society*, 54(6), 627-635, 2003.
- [10] Yulianti, E., Putri, F. K., & Saifudin, A., "Perbandingan Algoritma Decision Tree, Naive Bayes dan k-NN untuk Prediksi Kelayakan Kredit," *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, 4(1), 9-16, 2020.
- [11] Menardi, G., & Torelli, N., "Training and assessing classification rules with imbalanced data," *Data Mining and Knowledge Discovery*, 28(1), 92-122, 2014.